

Aplicações do Teorema de Frisch-Waugh-Lovell

Apoio aos alunos de Econometria e capacitação de
futuros docentes

Gustavo de Oliveira Vital

Universidade Federal Fluminense - Faculdade de Economia

18/10/2018

Sumário

Apresentação do Teorema

Prova do Teorema

Um Exemplo Prático
As estimações

Conclusão

Outras Aplicações

Bibliografia

Aplicações do
Teorema de Frisch-
Vaughan-Lovell

Gustavo de
Oliveira Vital

Apresentação do
Teorema

Prova do Teorema

Um Exemplo
Prático

As estimações

Conclusão

Outras Aplicações

Bibliografia

Apresentação do Teorema

Aplicações do
Teorema de Frisch-
Waugh-Lovell

Gustavo de
Oliveira Vital

Dado um modelo Linear, estimado por Mínimos Quadrados Ordinários (MQO):

$$\mathbf{y} = \mathbf{X}\beta + \mathbf{u}$$

Em que y é a variável dependente, sendo representada por um vetor $\mathbf{n} \times \mathbf{1}$; \mathbf{X} é a matriz de variáveis explicativas, tal que assumimos que essa seja $\mathbf{n} \times \mathbf{k}$; β é o vetor de coeficientes da regressão, sendo esse um vetor $\mathbf{k} \times \mathbf{1}$ e \mathbf{u} o vetor do termo de erro, $\mathbf{n} \times \mathbf{1}$.

Podemos transformar esse modelo tal que esse seja representado da seguinte forma:

$$\mathbf{y} = \mathbf{X}_1\beta_1 + \mathbf{X}_2\beta_2 + \mathbf{u}$$

Apresentação do
Teorema

Prova do Teorema

Um Exemplo
Prático

As estimações

Conclusão

Outras Aplicações

Bibliografia

Apresentação do Teorema

Aplicações do
Teorema de Frisch-
Waugh-Lovell

Gustavo de
Oliveira Vital

Apresentação do
Teorema

Prova do Teorema

Um Exemplo
Prático

As estimações

Conclusão

Outras Aplicações

Bibliografia

A proposta de FWL é mostrar que os estimadores de qualquer variável no modelo múltiplo podem ser obtidos se “neutralizarmos” os efeitos das demais variáveis. Dito de outra forma, se dividirmos a matriz de regressores em 2 grupos de variáveis, basta eliminar os efeitos de um deles para obter o estimador do grupo de interesse do pesquisador.

Apresentação do Teorema

Aplicações do
Teorema de Frisch-
Waugh-Lovell

Gustavo de
Oliveira Vital

O teorema de FWL apresenta dois resultados:

- ▶ As estimativas de mínimos quadrados das regressões (1) e (2) abaixo descritas são numericamente idênticas;
- ▶ Os resíduos de mínimos quadrados das regressões (1) e (2) abaixo descritas são numericamente idênticos.

$$\mathbf{y} = \mathbf{X}_1\beta_1 + \mathbf{X}_2\beta_2 + \mathbf{u} \quad (1)$$

$$\mathbf{M}_1\mathbf{y} = \mathbf{M}_1\mathbf{X}_2\beta_2 + \text{resíduos} \quad (2)$$

em que \mathbf{M}_1 é a matriz que projeta no $\text{Span}^\perp(\mathbf{X}_1)$
No modelo acima, particionamos $\mathbf{X} = [\mathbf{X}_1 \quad \mathbf{X}_2]$. Além disso, β_1 terá k_1 componentes e β_2 terá k_2 componentes, em que $k = k_1 + k_2$.

Apresentação do
Teorema

Prova do Teorema

Um Exemplo
Prático

As estimações

Conclusão

Outras Aplicações

Bibliografia

Apresentação do Teorema

Aplicações do
Teorema de Frisch-
Waugh-Lovell

Gustavo de
Oliveira Vital

Nota 1

A matriz \mathbf{M}_1 é dita aniquiladora de \mathbf{X}_1 pois projeta ortogonalmente as colunas de \mathbf{X}_1 no $\text{Span}^\perp(\mathbf{X}_1)$. Como \mathbf{X}_1 é parte de \mathbf{X} (lembre que particionamos $\mathbf{X} = [\mathbf{X}_1 \quad \mathbf{X}_2]$), podemos escrever que:

Apresentação do
Teorema

Prova do Teorema

Um Exemplo
Prático

As estimações

Conclusão

Outras Aplicações

Bibliografia

$$\mathbf{M}_1\mathbf{X}_1 = (\mathbf{I} - \mathbf{P}_1)\mathbf{X}_1 = \mathbf{X}_1 - \mathbf{P}_{\mathbf{X}_1}\mathbf{X}_1 = \mathbf{X}_1 - \mathbf{X}_1 = \mathbf{0}$$

A penúltima igualdade decorre do fato de \mathbf{X}_1 ser invariante sob a ação de \mathbf{P}_1 , a matriz de projeção no $\text{Span}(\mathbf{X}_1)$.

Nota 2

Veja que não incluímos nenhuma caracterização mais objetiva dos resíduos. Isso decorre fundamentalmente de razões geométricas.

Prova do Teorema

Aplicações do
Teorema de Frisch-
Waugh-Lovell

Gustavo de
Oliveira Vital

Apresentação do
Teorema

Prova do Teorema

Um Exemplo
Prático

As estimações

Conclusão

Outras Aplicações

Bibliografia

Pela fórmula geral do estimador de Mínimos Quadrados Ordinários, temos que:

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$$

O estimador de (2) é:

$$(\mathbf{M}_2'\mathbf{M}_1\mathbf{X}_2)^{-1}\mathbf{X}_2'\mathbf{M}_1\mathbf{y} \quad (3)$$

Sejam β_1 e β_2 os dois vetores de coeficientes estimados de (1). Então:

$$\mathbf{y} = \mathbf{P}_x\mathbf{y} + \mathbf{M}_x\mathbf{y} = \mathbf{X}_1\hat{\beta}_1 + \mathbf{X}_2\hat{\beta}_2 + \mathbf{M}_x\mathbf{y} \quad (4)$$

Premultiplicando o lado esquerdo e o direito da expressão (4) por $\mathbf{X}_2'\mathbf{M}_1$ nós obtemos:

Prova do Teorema

Aplicações do
Teorema de Frisch-
Waugh-Lovell

Gustavo de
Oliveira Vital

Apresentação do
Teorema

Prova do Teorema

Um Exemplo
Prático

As estimações

Conclusão

Outras Aplicações

Bibliografia

$$\mathbf{X}_2' \mathbf{M}_1 \mathbf{y} = \mathbf{X}_2' \mathbf{M}_1 \mathbf{X}_2 \hat{\beta}_2 \quad (5)$$

O primeiro termo do lado direito de (4) some, pois \mathbf{M}_1 aniquila \mathbf{X}_1 . Podemos observar que o último termo também some:

$$\mathbf{M}_X \mathbf{M}_1 \mathbf{M}_2 = \mathbf{M}_X \mathbf{X}_2 = \mathbf{0}$$

Agora nós podemos solucionar (5) em relação à $\hat{\beta}_2$:

$$\hat{\beta}_2 = (\mathbf{X}_2' \mathbf{M}_1 \mathbf{X}_2)^{-1} \mathbf{X}_2' \mathbf{M}_1 \mathbf{y}$$

Isso é: a expressão (3). Isso prova *parte* do teorema.

Prova do Teorema

Aplicações do
Teorema de Frisch-
Waugh-Lovell

Gustavo de
Oliveira Vital

Se premultiplicarmos (4) por \mathbf{M}_1 ao invés de $\mathbf{X}_2'\mathbf{M}_1$ nós iremos obter:

$$\mathbf{M}_1\mathbf{y} = \mathbf{M}_1\mathbf{X}_2\hat{\beta}_2 + \mathbf{M}_1\mathbf{xy} \quad (6)$$

Onde o último termo permanece inalterado, pois $\mathbf{M}_1\mathbf{M}_x = \mathbf{M}_x$. O regressando de (6) é o regressando da regressão (2). Como $\hat{\beta}$ é uma estimação de β (1), pela primeira parte do teorema, o primeiro termo do lado direito de (6) é o vetor de valores estimados da regressão. Ainda, o segundo termo tem que ser o vetor de resíduos da regressão (1). Como $\mathbf{M}_1\mathbf{xy}$ é, *também*, o vetor de resíduos da regressão (1), isso prova a segunda parte do teorema.

Apresentação do
Teorema

Prova do Teorema

Um Exemplo
Prático

As estimações

Conclusão

Outras Aplicações

Bibliografia

Um Exemplo Prático

Aplicações do
Teorema de Frisch-
Waugh-Lovell

Gustavo de
Oliveira Vital

Por fim, nesta última sessão do trabalho, o objetivo será apresentar um modelo teórico que tem como objetivo estimar a variação salarial no estado do Rio de Janeiro. A base de dados utilizada será a PNAD (Pesquisa Nacional por Amostra em Domicílios) de pessoas (PNADPes) do ano de 2015. Ainda que esse não seja o banco de dados atual - a própria PNAD foi descontinuada e hoje é implementada a PNADC (Pesquisa Nacional por Amostra em Domicílios Contínua) - servirá como um exemplo prático da implementação deste teorema. Foi pensado um modelo que leve em consideração o Sexo da pessoa, a Idade e Anos de Estudo.

Apresentação do
Teorema

Prova do Teorema

**Um Exemplo
Prático**

As estimações

Conclusão

Outras Aplicações

Bibliografia

Um Exemplo Prático

Aplicações do
Teorema de Frisch-
Waugh-Lovell

Gustavo de
Oliveira Vital

O modelo assumirá a seguinte forma:

$$\ln(\text{salario}) = \beta_0 + \text{idade}\beta_1 + \text{sexo}\beta_2 + \text{educ}\beta_3 + u$$

Ressalto, ainda, que o objetivo não é melhorar o modelo, seja em relação à acrescimos de variáveis ou mesmo em relação a correção de heterocedasticidade. O presente exemplo visa **somente** demonstrar uma aplicação referente ao teorema de FWL.

Os resultados das estimações foram obtidos a partir da linguagem *Python*, especificamente utilizando o modulo *statsmodels*, e a leitura dos dados com o software *R*.

Apresentação do
Teorema

Prova do Teorema

Um Exemplo
Prático

As estimações

Conclusão

Outras Aplicações

Bibliografia

As estimações

Aplicações do
Teorema de Frisch-
Waugh-Lovell

Gustavo de
Oliveira Vital

Dado o modelo apresentado :

$$\ln(\text{salario}) = \beta_0 + \text{idade}\beta_1 + \text{sexo}\beta_2 + \text{educ}\beta_3 + u$$

Estimamos ele em sua forma completa após importarmos os modulos necessários:

```
import pandas as pd
import statsmodels.api as sm
import numpy as np
import matplotlib.pyplot as plt
from matplotlib import rc

pnad = pd.read_csv('dadosRJ.csv')
pnad = pnad[['V8005', 'V9532', 'V4803', 'V0302']]
pnad = pnad.rename({'V8005': 'idade', 'V9532': 'salmes', 'V4803': 'educ', 'V0302': 'sexo'},
                    axis='columns')
```

Apresentação do
Teorema

Prova do Teorema

Um Exemplo
Prático

As estimações

Conclusão

Outras Aplicações

Bibliografia

As estimações

Aplicações do
Teorema de Frisch-
Waugh-Lovell

Gustavo de
Oliveira Vital

Apresentação do
Teorema

Prova do Teorema

Um Exemplo
Prático

As estimações

Conclusão

Outras Aplicações

Bibliografia

Após termos importado os módulos, renomeamos as variáveis e criamos um novo *dataframe* (com o mesmo nome), usando somente as variáveis necessárias.

De acordo com o dicionário da PNAD de 2015, salário (*proxy*) é representado pelo código: 'V9532'; sexo pelo código: 'V0302'; idade pelo código: 'V8005'; e escolaridade(*proxy*) pelo código: 'V4803'. Retiramos os *missings* das variáveis e o valor '17' do código referente à educação, por ser não determinado. Além disso, aplicaremos o *log* na variável *salmes*, para trabalharmos com a variação. Ainda, por sexo ser uma variável *dummy*, assumiremos $\text{mulher} = 1$; $\text{homem} = 0$.

As estimações

Aplicações do
Teorema de Frisch-
Waugh-Lovell

Gustavo de
Oliveira Vital

Apresentação do
Teorema

Prova do Teorema

Um Exemplo
Prático

As estimações

Conclusão

Outras Aplicações

Bibliografia

```
lnsalmes = np.log(pnad['salmes'])
pnad['lnsalmes'] = lnsalmes # len = 25858
pnad = pnad[(pnad.educ < 17)] # len = 25829
pnad = pnad.dropna() # len = 11471
pnad['sexo'] = pnad['sexo'].map({4: 1, 2: 0})
```

Como, por *default* o modulo *statsmodels* não inclui constante no modelo, temos que adicionar uma coluna de “uns”:

```
pnad = sm.add_constant(pnad)
```

Feito isso, só nos resta estimar o modelo: coluna de “uns”:

```
y = pnad['lnsalmes']
X = pnad[['const', 'idade', 'sexo', 'educ']]

modelo = sm.OLS(y, X)
ajuste = modelo.fit()

print(ajuste.summary().as_latex())
```

As estimações

Aplicações do
Teorema de Frisch-
Waugh-Lovell

Gustavo de
Oliveira Vital

Após estimarmos o modelo, sob a forma

$$\ln(\text{salario}) = \beta_0 + \text{idade}\beta_1 + \text{sexo}\beta_2 + \text{educ}\beta_3 + u,$$

obtivemos o seguinte resultado:

Dep. Variable:	Insalmes	R-squared:	0.062			
Model:	OLS	Adj. R-squared:	0.061			
Method:	Least Squares	F-statistic:	250.9			
Date:	Sat, 06 Oct 2018	Prob (F-statistic):	9.75e-158			
Time:	02:10:11	Log-Likelihood:	-28027.			
No. Observations:	11476	AIC:	5.606e+04			
Df Residuals:	11472	BIC:	5.609e+04			
Df Model:	3					
	coef	std err	t	P> t 	[0.025	0.975]
const	4.8823	0.123	39.660	0.000	4.641	5.124
idade	0.0251	0.002	12.476	0.000	0.021	0.029
sexo	-0.3950	0.053	-7.494	0.000	-0.498	-0.292
educ	0.1755	0.007	25.793	0.000	0.162	0.189
Omnibus:	13384.632	Durbin-Watson:	1.369			
Prob(Omnibus):	0.000	Jarque-Bera (JB):	936746.793			
Skew:	6.430	Prob(JB):	0.00			
Kurtosis:	45.351	Cond. No.	209.			

Apresentação do
Teorema

Prova do Teorema

Um Exemplo
Prático

As estimações

Conclusão

Outras Aplicações

Bibliografia

As estimações

A partir de agora, faremos o mesmo procedimento regredindo as variáveis explicativas e a variável dependente contra *idade*, e extraíndo de cada uma os resíduos das regressões:

```
M1y = sm.OLS(pnad['lnsalmes'], pnad[['const', 'idade']]).fit().resid
M1X2 = sm.OLS(pnad['educ'], pnad[['const', 'idade']]).fit().resid
M1X3 = sm.OLS(pnad['sexo'], pnad[['const', 'idade']]).fit().resid
```

Adiciono os resultados no *dataframe* pnad e faço outra estimação - dessa vez referente ao modelo com as matrizes aniquiladoras de *idade*:

```
pnad['M1y'] = M1y
pnad['M1X2'] = M1X2
pnad['M1X3'] = M1X3
modelo2 = sm.OLS(pnad['M1y'], pnad[['const', 'M1X2', 'M1X3']])
ajuste2 = modelo2.fit()
```


As estimações

Aplicações do
Teorema de Frisch-
Waugh-Lovell

Gustavo de
Oliveira Vital

Aplicando o seguinte comando iremos obteremos o *output*.

```
print(ajuste2.summary())
```

Dep. Variable:	M1y	R-squared:	0.057			
Model:	OLS	Adj. R-squared:	0.056			
Method:	Least Squares	F-statistic:	343.8			
Date:	Sat, 06 Oct 2018	Prob (F-statistic):	1.01e-145			
Time:	02:00:10	Log-Likelihood:	-28027.			
No. Observations:	11476	AIC:	5.606e+04			
Df Residuals:	11473	BIC:	5.608e+04			
Df Model:	2					
	coef	std err	t	P> t 	[0.025	0.975]
const	5.496e-15	0.026	2.12e-13	1.000	-0.051	0.051
M1X2	0.1755	0.007	25.794	0.000	0.162	0.189
M1X3	-0.3950	0.053	-7.494	0.000	-0.498	-0.292
Omnibus:	13384.632	Durbin-Watson:	1.369			
Prob(Omnibus):	0.000	Jarque-Bera (JB):	936746.793			
Skew:	6.430	Prob(JB):	0.00			
Kurtosis:	45.351	Cond. No.	7.80			

De fato, isso nos leva a crer que $\hat{\beta}_2$ e $\hat{\beta}_3$ são iguais em âmbos os modelos.

Apresentação do
Teorema

Prova do Teorema

Um Exemplo
Prático

As estimações

Conclusão

Outras Aplicações

Bibliografia

Conclusão

De fato, podemos concluir que os coeficientes são iguais, sendo essa uma maneira alternativa de estimação de MQO. Além disso, podemos chegar a uma outra conclusão. Os resíduos dos dois modelos são os mesmos. Como “*idade*” está incorporada ao segundo modelo por meio da matriz aniquiladora essa variável ainda se apresenta por meio dessa matriz. Com mais algumas linhas de códigos podemos conferir ao gráfico de dispersão dos resíduos dos dois modelos. Assim, não só os coeficientes $\hat{\beta}_2$ e $\hat{\beta}_3$ são iguais, mas os resíduos \hat{u}_1 e \hat{u}_2 também - sendo o primeiro referente ao modelo com *idade* e o segundo ao modelo com a matriz aniquiladora de *idade*.

Aplicações do
Teorema de Frisch-
Waugh-Lovell

Gustavo de
Oliveira Vital

Apresentação do
Teorema

Prova do Teorema

Um Exemplo
Prático

As estimações

Conclusão

Outras Aplicações

Bibliografia

Visualizando o gráfico de resíduos

Aplicações do
Teorema de Frisch-
Waugh-Lovell

Gustavo de
Oliveira Vital

```
rc('font', **{'family': 'sans-serif', 'sans-serif': ['Helvetica']})
rc('text', usetex=True)

plt.subplot(2, 1, 1)
plt.plot(ajuste.resid, 'o', alpha=0.2, color='red')

plt.title(r"Resíduos de  $y = X\beta + \mu$ ",
          fontsize=16)

plt.subplot(2, 1, 2)
plt.plot(ajuste2.resid, 'o', alpha=0.2)
plt.title(r"Resíduos de  $M_{X1}y = M_{X1}X_{\{2\}}\beta_{\{2\}} + M_{X1}X_{\{3\}}\beta_{\{3\}} + M_{X1}\mu$ ",
          fontsize=16)

plt.tight_layout()
plt.show()
```

Que nos dá o seguinte resultado:

Apresentação do
Teorema

Prova do Teorema

Um Exemplo
Prático

As estimações

Conclusão

Outras Aplicações

Bibliografia

Gráficos de Resíduos

Aplicações do
Teorema de Frisch-
Waugh-Lovell

Gustavo de
Oliveira Vital

Apresentação do
Teorema

Prova do Teorema

Um Exemplo
Prático


As estimações

Conclusão


Outras Aplicações

Bibliografia

Resíduos de $y = X\beta + \mu$



Resíduos de $M_{X_1}y = M_{X_1}X_2\beta_2 + M_{X_1}X_3\beta_3 + M_{X_1}\mu$



Outras Aplicações

- ▶ Sazonalidade
- ▶ Tendência
- ▶ Sub e superspecificação

Aplicações do
Teorema de Frisch-
Waugh-Lovell

Gustavo de
Oliveira Vital

Apresentação do
Teorema

Prova do Teorema

Um Exemplo
Prático

As estimações

Conclusão

Outras Aplicações

Bibliografia

Bibliografia

Aplicações do Teorema de Frisch-Waugh-Lovell

Gustavo de
Oliveira Vital

Bibliografia



Davidson, R., MacKinnon, J. G., et al. (2004).

Econometric theory and methods, volume 5.

Oxford University Press New York.



Frisch, R. and Waugh, F. V. (1933).

Partial time regressions as compared with individual trends.

Econometrica: Journal of the Econometric Society, pages 387–401.



Lovell, M. (2007).

A simple proof of the fwl (frisch-waugh-lovell) theorem.

Wesleyan Economics Working Papers 2005-012, Wesleyan University, Department of Economics.



Seabold, S. and Perktold, J. (2010).

Statsmodels: Econometric and statistical modeling with python.

In 9th Python in Science Conference.